CẢI THIỆN HIỆU NĂNG PHÁT HIỆN VẬT THỂ NỔI BẬT VỚI U²-NET DỰA TRÊN KIẾN TRÚC U LỒNG NHAU

IMPROVING SALIENT OBJECT DETECTION PERFORMANCE WITH U²-NET BASED ON A NESTED U-ARCHITECTURE

SVTH: Nguyễn Văn Quý, Hồ Nguyên Tâm, Trần Đăng Bách

Lớp: 22KTMT1&2; Khoa Điện Tử - Viễn Thông, Trường Đại học Bách khoa Đại học Đà Nẵng; Email: nquy1357@gmail.com, honguyentam57@gmail.com, bach9747@gmail.com.

GVHD: TS. Hồ Phước Tiến

Khoa: Điện Tử - Viễn Thông, Trường: Đại học Bách khoa Đại học Đà Nẵng

Link code github: https://github.com/tiroin/U-2_Net_Model.git

Tóm tắt - Bài báo trình bày nghiên cứu về bài toán phát hiện vật thể nổi bật (Salient Object Detection – SOD) sử dụng kiến trúc U²-Net. Đây là mô hình dựa trên cấu trúc U lồng nhau, trong đó các khối Residual U-block (RSU) cho phép trích xuất đặc trưng đa tỉ lệ, kết hợp thông tin cục bộ và ngữ cảnh toàn cục mà không phụ thuộc vào backbone tiền huấn luyện. Trong nghiên cứu này, mô hình được huấn luyện từ đầu trên bộ dữ liệu DUTS-TR và đánh giá trên các tập dữ liệu chuẩn như DUTS-TE và ECSSD. Nhằm cải thiện chất lượng bản đồ nổi bật, nhóm áp dụng hàm mất mát kết hợp gồm Binary Cross-Entropy, SSIM Loss và IoU Loss, giúp mô hình đồng thời tối ưu sai số theo từng pixel, cấu trúc biên và mức độ chồng lấp của vùng đối tượng. Bên cạnh đó, quy trình huấn luyện được hiệu chỉnh thông qua các kỹ thuật như data augmentation, learning rate scheduler, early stopping và checkpoint nhằm tăng độ ổn định trong điều kiện phần cứng hạn chế. Kết quả thực nghiệm cho thấy hướng tiếp cận này giúp cải thiện chất lượng phân đoạn, tạo ra mask có cấu trúc rõ hơn, biên đối tượng sắc nét hơn và khả năng tổng quát hóa tốt hơn trên các tập dữ liệu đánh giá.

Từ khóa - Salient Object Detection, U²-Net, Residual U-block, Hybrid Loss, phân đoạn ảnh

Abstract - This paper presents a study on Salient Object Detection (SOD) using the U²-Net architecture. U²-Net is built upon a nested U-shaped structure, in which Residual U-blocks (RSUs) enable multi-scale feature extraction by combining local details with global contextual information without relying on pretrained backbones. In this study, the model is trained from scratch on the DUTS-TR dataset and evaluated on standard benchmarks such as DUTS-TE and ECSSD. To improve the quality of the predicted saliency maps, a hybrid loss function is adopted by combining Binary Cross-Entropy, SSIM Loss, and IoU Loss. This design allows the model to jointly optimize pixel-level accuracy, boundary structure, and region overlap between the predicted mask and the ground truth. In addition, the training pipeline is enhanced with data augmentation, a learning rate scheduler, early stopping, and checkpointing to improve training stability under limited hardware conditions. Experimental results show that the proposed training strategy improves segmentation quality, producing saliency maps with clearer object structures, sharper boundaries, and better generalization on evaluation datasets.

Key words - Salient Object Detection, U²-Net, Residual U-block, Hybrid Loss, image segmentation

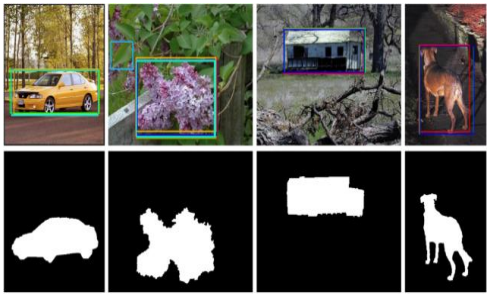
1. Mô tả bài toán

1.1. Bài toán Phát hiện Vật thể Nổi bật (Salient Object Detection – SOD)

Phát hiện vật thể nổi bật (Salient Object Detection – SOD) là một bài toán thuộc lĩnh vực phân đoạn ảnh ở mức điểm ảnh, với mục tiêu xác định những vùng hoặc đối tượng thu hút sự chú ý thị giác nhiều nhất trong ảnh. Khác với bài toán phân loại ảnh chỉ đưa ra nhãn tổng quát cho toàn bộ ảnh, SOD yêu cầu mô hình phải dự đoán chính xác từng pixel thuộc về đối tượng nổi bật hay thuộc về phông nền.

Đầu ra của bài toán thường là một bản đồ độ nổi bật nhị phân (binary saliency map), trong đó mỗi pixel được gán giá trị 1 nếu thuộc vùng vật thể nổi bật và giá trị 0 nếu thuộc vùng nền. Nhờ đó, đối tượng chính trong ảnh có thể được tách ra rõ ràng khỏi bối cảnh xung quanh, phục vụ cho các bước xử lý ảnh tiếp theo.

Bài toán SOD có ý nghĩa thực tiễn cao và được ứng dụng rộng rãi trong nhiều lĩnh vực như theo dõi đối tượng, cắt ảnh thông minh, tóm tắt video, nhận dạng đối tượng trong môi trường phức tạp và phân tích ảnh y sinh. Việc phát hiện chính xác vùng nổi bật giúp hệ thống tập trung vào những thông tin quan trọng nhất trong ảnh, từ đó nâng cao hiệu quả của các bài toán thị giác máy tính phía sau.

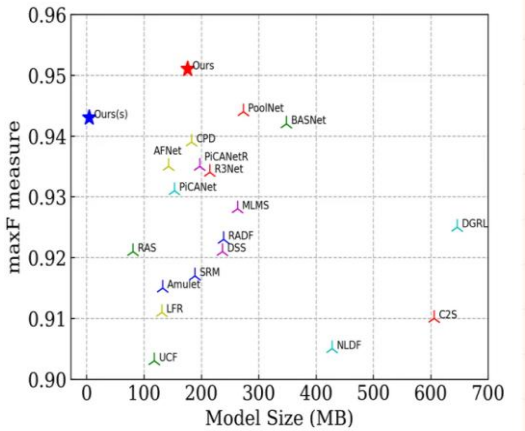


Hình 1. Bài toán SOD – Salient Object Detection

1.2. Vấn đề của các phương pháp hiện tại

Phần lớn mô hình deep learning hiện đại cho SOD xây dựng trên các backbone phân loại tiền huấn luyện (VGG, ResNet, DenseNet). Những backbone này được thiết kế cho bài toán phân loại ảnh, do đó:

- Ưu tiên đặc trưng ngữ nghĩa cấp cao, thiếu thông tin chi tiết cục bộ (cạnh, biên, hình dạng).
- Quá trình downsampling mạnh làm mất độ phân giải không gian.
- Mô hình phụ thuộc vào bộ trọng số pretrained từ ImageNet, làm giảm tính linh hoạt.
- Chi phí lưu trữ lớn: một số mô hình SOTA có kích thước 300–650 MB.



Hình 2. So sánh kích thước mô hình

1.3. Mục tiêu

Đề tài nhằm thiết kế và huấn luyện mô hình U²-Net với các mục tiêu cụ thể:

- Huấn luyện từ đầu (from scratch): không phụ thuộc backbone tiền huấn luyện ImageNet, giúp mô hình linh hoạt và phù hợp hơn với bài toán SOD.
- Nắm bắt đặc trưng đa tỉ lệ (multi-scale): khai thác cả thông tin cục bộ (cạnh, vân, hình dạng) lẫn ngữ cảnh toàn cục (vị trí đối tượng trong ảnh).
- Duy trì độ phân giải cao: tránh mất thông tin không gian trong quá trình downsampling.
- Cân bằng độ sâu mạng và chi phí tính toán: tăng khả năng biểu diễn mà không tăng đáng kể số tham số.
- Cải tiến hàm mất mát: sử dụng Hybrid Loss (BCE + SSIM + IoU) để cải thiện chất lượng phân đoạn biên và vùng đối tượng.

2. Mô hình

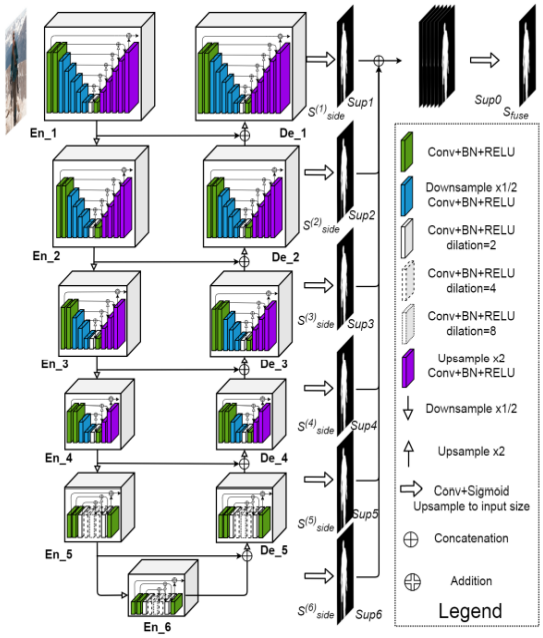
2.1. Tổng quan kiến trúc U² net

U²-Net (Squared U-Net) là kiến trúc được phát triển dựa trên ý tưởng của U-Net, cụ thể là cấu trúc encoder–decoder kết hợp với các kết nối tắt (skip connection) để vừa khai thác thông tin ngữ cảnh toàn cục, vừa bảo toàn chi tiết không gian của ảnh. Tuy nhiên, điểm khác biệt của U²-Net là mô hình không chỉ sử dụng một cấu trúc U-Net ở mức tổng thể, mà còn lồng thêm các U-Net thu nhỏ bên trong từng khối xử lý đặc trưng. Các khối này được gọi là Residual U-block (RSU).

Nói cách khác, U²-Net có thể được xem là một kiến trúc "U trong U", trong đó mỗi khối tích chập thông thường trong mạng được thay thế bằng một khối RSU có khả năng học đặc trưng đa tỉ lệ. Nhờ vậy, mô hình có thể tăng khả năng biểu diễn đặc trưng mà vẫn kiểm soát được số lượng tham số và chi phí tính toán.

Toàn bộ mạng U²-Net bao gồm ba thành phần chính:

- Encoder (En_1 đến En_6): gồm 6 tầng mã hóa, sử dụng các khối RSU với độ sâu khác nhau nhằm trích xuất đặc trưng ở nhiều mức độ phân giải.
- Decoder (De_1 đến De_5): gồm 5 tầng giải mã có cấu trúc đối xứng với encoder, kết hợp đặc trưng từ các tầng mã hóa thông qua skip connection để khôi phục thông tin không gian và chi tiết biên.
- Saliency Map Fusion Module: tổng hợp 6 bản đồ dự đoán phụ từ các tầng khác nhau, sau đó kết hợp chúng để tạo ra bản đồ độ nổi bật cuối cùng.



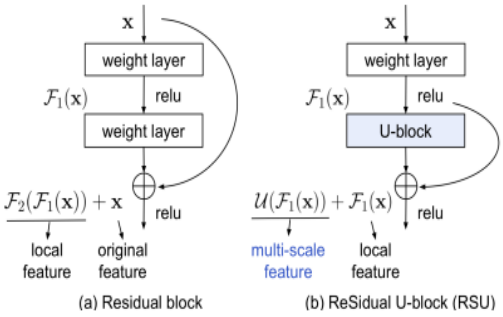
Hình 3. Kiến trúc tổng thể U²-Net

2.2. Khối Residual U-block (RSU)

RSU là khối cốt lõi của U²-Net, hoạt động như một U-Net thu nhỏ bên trong mỗi tầng. Cấu trúc RSU-L gồm:

- Conv3×3 đầu vào: trích xuất đặc trưng ban đầu $F_1(x)$ từ ảnh đầu vào.

- U-Net nội bộ (U-block): encoder-decoder với L tầng, học ngữ cảnh toàn cục và chi tiết cục bộ ở nhiều tỉ lệ khác nhau.
- Residual connection: $H_RSU(x) = U(F_1(x)) + F_1(x)$, giữ thông tin gốc, ổn định gradient và làm giàu đặc trưng.



Hình 4. So sánh residual block và RSU

So với residual block truyền thống H(x) = F2(F1(x)) + x, RSU thay thế khối tích chập thứ hai bằng U-Net nội bộ, cho phép học đặc trưng đa tỉ lệ mà không cần tăng số tham số đáng kể.

2.3. Các biến thể RSU trong mạng

Tùy theo vị trí trong mạng (độ phân giải feature map), U²-Net sử dụng các biến thể RSU khác nhau:

***Bảng 1**. Các biến thể RSU*

Khối	Số tầng L	Vị trí	Đặc điểm
RSU-7	7	En_1, De_1	Độ phân giải cao, nhiều tầng pooling
RSU-6	6	En_2, De_2	Độ phân giải trung bình-cao
RSU-5	5	En_3, De_3	Độ phân giải trung bình
RSU-4	4	En_4, De_4	Độ phân giải trung bình-thấp
RSU-4F	4 (dilated)	En_5, En_6, De_5	Dùng dilated conv thay pooling – giữ độ phân giải thấp không bị mất thêm

2.4. Tích chập giãn (Dilated Convolution) trong RSU-4F

Ở các tầng sâu (En_5, En_6), độ phân giải feature map đã rất thấp. Nếu tiếp tục dùng MaxPooling sẽ mất hoàn toàn thông tin không gian. Thay vào đó, RSU-4F sử dụng tích chập giãn (dilated convolution) với các hệ số d = 1, 2, 4, 8:

$$(y *_d f)(x) = \sum_{i+dj=x} y(i)f(j) \qquad (1)$$

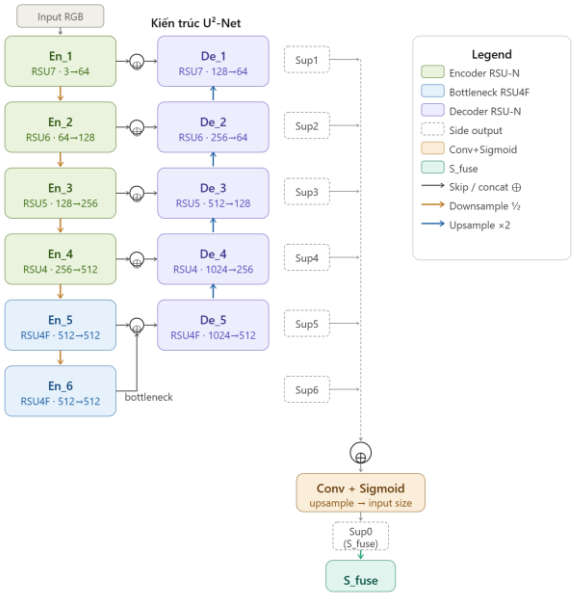
Trong đó d là hệ số giãn (dilation rate). Với d > 1, kernel lấy mẫu giãn cách, mở rộng vùng quan sát (receptive field) mà không tăng số tham số và không giảm độ phân giải.

2.5. Saliency Map Fusion Module

Mạng tạo ra 6 bản đồ dự đoán phụ (S_1_side đến S_6_side) từ mỗi giai đoạn của decoder và encoder cuối (En_6). Tất cả được:

- Upsample về cùng kích thước ảnh gốc bằng Conv và Sigmoid.
- Nối lại (concatenate) thành tensor 6 kênh.
- Đưa qua một lớp Conv 1x1 để tạo bản đồ dự đoán cuối cùng S_fuse.

2.6. Kiến trúc U²-Net trong code



Hình 5. Mô hình kiến trúc U²-Net

Trong code, mạng U²Net được định nghĩa với 6 tầng encoder và 5 tầng decoder giống ở phần kiến trúc tổng thể. Chi tiết bao gồm:

***Bảng 2.** Các tầng encoder và decoder của U²Net*

Tầng	Khối RSU	In → Out channels	Ghi chú
stage1 (En_1)	RSU7(3, 32, 64)	3 → 64	Input RGB
stage2 (En_2)	RSU6(64, 32, 128)	64 → 128	
stage3 (En_3)	RSU5(128, 64, 256)	128 → 256	
stage4 (En_4)	RSU4(256, 128, 512)	256 → 512	
stage5 (En_5)	RSU4F(512, 256, 512)	512 → 512	Dilated conv
stage6 (En_6)	RSU4F(512, 256, 512)	512 → 512	Bottleneck
stage5d (De_5)	RSU4F(1024, 256, 512)	1024 → 512	Cat với En_5
stage4d (De_4)	RSU4(1024, 128, 256)	1024 → 256	Cat với En_4
stage3d (De_3)	RSU5(512, 64, 128)	512 → 128	Cat với En_3
stage2d (De_2)	RSU6(256, 32, 64)	256 → 64	Cat với En_2
stage1d (De_1)	RSU7(128, 16, 64)	128 → 64	Cat với En_1

3. Dữ liệu

3.1. Các bộ dữ liệu sử dụng

Nhóm sử dụng hai bộ dữ liệu chuẩn cho bài toán Salient Object Detection:

3.1.1. DUTS (Detection and Segmentation of Salient Objects)



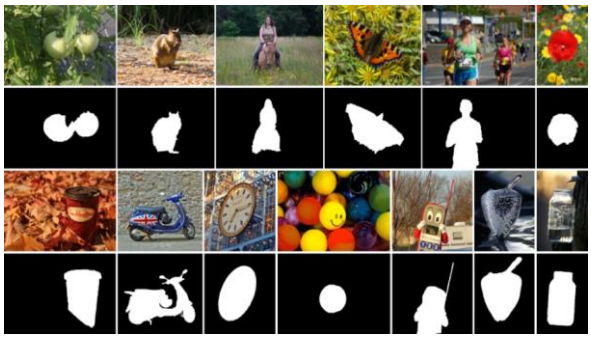
Hình 6. Ảnh và mask từ DUTS-TR

Nguồn gốc: là bộ dữ liệu benchmark lớn nhất cho SOD, tải từ http://saliencydetection.net/duts/. Bao gồm:

- DUTS-TR (Training set): 10,553 ảnh RGB cùng binary mask ground truth tương ứng.
- DUTS-TE (Test set): 5,019 ảnh, dùng làm tập validation trong thực nghiệm.

Đặc điểm của bộ dữ liệu này: các ảnh trong tập dữ liệu đến từ ImageNet, đa dạng chủ thể (người, động vật, xe, phong cảnh), nền tương đối rõ ràng.

3.1.2. ECSSD (Extended Complex Scene Saliency Dataset)



Hình 7. Ảnh và mask từ ECSSD

Số lượng: 1,000 ảnh RGB cùng binary mask ground truth.

Đặc điểm: ảnh có background rất phức tạp, nhiều chi tiết gây rối nhiễu, đối tượng không phải lúc nào cũng rõ ràng.

Nhóm sử dụng ECSSD làm tập validation thay thế khi không có DUTS-TE, qua đó kiểm tra khả năng tổng quát hóa mô hình trên dữ liệu khó hơn.

3.2. Phân chia dữ liệu

Chiến lược phân chia dữ liệu trong code:

- Ưu tiên: dùng toàn bộ DUTS-TR (10,553 ảnh) cho training, DUTS-TE (5,019 ảnh) cho validation.
- Fallback: nếu không tìm thấy DUTS-TE, tự động tách ngẫu nhiên 20% DUTS-TR làm validation (random split với random_state=42), đảm bảo không bị lệch label và không trùng dữ liệu train/val.

Bảng 3. *Phân bổ dữ liệu*

Tập dữ liệu	Bộ dữ liệu nguồn	Số lượng ảnh	Vai trò
Training	DUTS-TR	10,553	Huấn luyện model
Validation	DUTS-TE (ưu tiên) hoặc 20% DUTS-TR (fallback)	5,019 / ~2,111	Đánh giá overfitting
Thực nghiệm 2	ECSSD (val)	1,000	So sánh tổng qu át hóa

3.3. Tiền xử lý và Data Augmentation

Pipeline tiền xử lý áp dụng cho tập training (qua transforms.Compose):

- RescaleT(320): resize về kích thước cố định 320×320 pixel.
- RandomCrop(256): crop ngẫu nhiên về 256×256 để tăng tính đa dạng và giảm overfitting.
- ToTensorLab(flag=0): chuyển từ numpy sang tensor PyTorch và chuẩn hóa ảnh theo ImageNet mean/std (R: (I-0.485)/0.229, G: (I-0.456)/0.224, B: (I-0.406)/0.225), đồng thời chuẩn hóa mask về [0,1].

Tập validation chỉ áp dụng RescaleT(320) + ToTensorLab(flag=0), không augmentation, để đảm bảo đánh giá khách quan.

```
transform=transforms.Compose([
    RescaleT(320),
    RandomCrop(256),
    RandomHFlip(),
    RandomBrightContrast(brightness=0.2, contrast=0.2),
    RandomRotation(max_angle=10),
    ToTensorLab(flag=0)
])
```

Hình 8. Code tiền xử lí

3.4. Đặc điểm kỹ thuật của dữ liệu

Mỗi sample gồm 1 ảnh RGB (3 kênh) và 1 binary mask ground truth (1 kênh, giá trị 0 hoặc 255 và được chuẩn hóa về [0,1]).

Batch size: 2 (giảm so với bản gốc 12 để phù hợp với VRAM 4.29 GB của RTX 3050).

DataLoader: num_workers=2, pin_memory=True để tối ưu tốc độ nạp dữ liệu.

4. Tiêu chí đánh giá

4.1. Hàm mất mát huấn luyện

4.1.1. Binary Cross-Entropy Loss (BCE)

BCE là hàm mất mát cơ bản nhất cho bài toán phân loại nhị phân từng pixel:

$$L_{BCE} = -\frac{1}{N}\sum[y_i \log(p_i) + (1 - y_i)\log(1 - p_i)] (2)$$

Trong đó y_i là nhãn ground truth (0 hoặc 1) và p_i là xác suất dự đoán của mô hình cho pixel i. Hàm này tính toán độc lập từng pixel, không quan tâm đến cấu trúc không gian.

Trong U²-Net, BCE được áp dụng cho cả 7 đầu ra (6 side outputs + 1 fusion output):

$$L_{total} = \sum_{k=0}^{6} BCE(d_k, y) (3)$$

4.1.2. SSIM Loss (Structural Similarity Index Measure)

SSIM Loss đo độ tương đồng cấu trúc giữa bản đồ dự đoán và ground truth, sử dụng cửa sổ Gaussian 11×11 (σ=1.5):

$$L_{SSIM} = 1 - mean\big(SSIM(\hat{y}, y)\big) (4)$$

$$SSIM(\hat{y}, y) = \frac{(2\mu_{\hat{y}}\mu_y + C_1)(2\sigma_{\hat{y}y} + C_2)}{(\mu_{\hat{y}}^2 + \mu_y^2 + C_1)(\sigma_{\hat{y}}^2 + \sigma_y^2 + C_2)} (5)$$

Trong đó μ là trung bình cục bộ, σ² là phương sai, $\sigma_{\hat{y}y}$ là hiệp phương sai, C_1 và C_2 là hằng số ổn định. SSIM phạt nặng khi biên bị mờ hoặc chi tiết nhỏ bị mất, bù cho điểm yếu của BCE vốn tính từng pixel độc lập.

4.1.3. IoU Loss (Intersection over Union)

IoU Loss (Soft IoU) tối ưu trực tiếp tỉ lệ chồng lấp giữa mask dự đoán và ground truth:

$$L_{IoU} = 1 - \frac{\sum(\hat{y} \cdot y) + \varepsilon}{\sum(\hat{y} + y - \hat{y} \cdot y) + \varepsilon} (6)$$

Trong đó ε = 1e-6 tránh chia cho 0. IoU = 1 khi dự đoán hoàn hảo (Loss = 0), IoU = 0 khi không có điểm chung (Loss = 1). Metric này buộc mô hình chú ý đến vùng đối tượng ngay cả khi nhỏ, khắc phục hiện tượng BCE bỏ qua vùng nhỏ do mất cân bằng foreground/background.

4.1.4. Hybrid Loss (cải tiến của nhóm)

Nhóm kết hợp ba hàm mất mát thành Hybrid Loss với trọng số bằng nhau:

$$L_{Hybrid} = w_{BCE} \cdot L_{BCE} + w_{SSIM} \cdot L_{SSIM} + w_{IoU} \cdot L_{IoU} (7)$$

với w_BCE = w_SSIM = w_IoU = 1.0 (có thể điều chỉnh). Hybrid Loss được áp dụng cho cả 7 đầu ra của mạng.

4.2. Các metric đánh giá trên tập validation

4.2.1. Mean Absolute Error (MAE)

MAE đo sai lệch trung bình tuyệt đối giữa mask dự đoán và ground truth ở mức pixel:

$$MAE = \frac{1}{N}\sum_{i=1}^{N} |p_i - y_i| (8)$$

MAE càng nhỏ càng tốt (↓). Đây là metric cơ bản và trực quan nhất để đo lường sai số pixel.

4.2.2. Max F-measure (maxFβ)

Fβ cân bằng giữa Precision và Recall, với β² = 0.3 (ưu tiên precision hơn recall):

$$F_\beta = \frac{(1 + \beta^2) \cdot Precision \cdot Recall}{\beta^2 \cdot Precision + Recall} (9)$$

maxFβ là giá trị Fβ tối đa đạt được khi thay đổi ngưỡng phân loại từ 0 đến 1. maxFβ càng cao càng tốt (↑). Trong SOD, việc giảm nhiễu nền (precision cao) quan trọng hơn việc bao phủ toàn bộ đối tượng (recall cao).

4.2.3. S-measure (Structure measure – Sm)

S-measure đánh giá cấu trúc không gian của mask dự đoán, gần với cách con người đánh giá chất lượng segmentation:

$$S_\alpha = \alpha \cdot S_o + (1 - \alpha) \cdot S_r \quad (\alpha = 0.5) (10)$$

Trong đó S_o đo tương đồng cấu trúc ở cấp độ đối tượng và S_r đo tương đồng ở cấp độ vùng. Sm càng cao càng tốt (↑). Sm phản ánh tốt hơn BCE và MAE về chất lượng hình dạng và biên.

4.2.4. Tổng hợp bảng tiêu chí

S-measure đánh giá cấu trúc không gian của mask dự đoán, gần với cách con người đánh giá chất lượng segmentation:

Bảng 4. *Tổng hợp tiêu chí*

Metric	Đo lường	Hướng tốt	Ý nghĩa thực tế
BCE Loss	Sai số từng pixel (log-loss)	↓ thấp hơn	Hàm tối ưu chính trong training
SSIM Loss	Sai lệch cấu trúc cục bộ	↓ thấp hơn	Biên sắc nét, ít nhiễu
IoU Loss	Overlap vùng đối tượng	↓ thấp hơn	Vùng foreground chính xác, ít lỗ hổng
MAE	Sai số pixel trung bình tuyệt đối	↓ thấp hơn	Sai số tổng thể mức pixel
maxFβ	Cân bằng Precision-Recall tối đa	↑ cao hơn	Chất lượng phân biệt foreground/background
S-measure (Sm)	Tương đồng cấu trúc hình dạng	↑ cao hơn	Hình dạng đối tượng khớp ground truth

5. Đánh giá và Nhận xét kết quả

5.1. Cấu hình thực nghiệm

Quá trình huấn luyện mô hình được thực hiện trên môi trường phần cứng có giới hạn về bộ nhớ GPU, do đó các tham số như batch size, learning rate và cơ chế dừng sớm được lựa chọn nhằm đảm bảo mô hình có thể huấn luyện ổn định.

Bảng 5. Cấu hình thực nghiệm

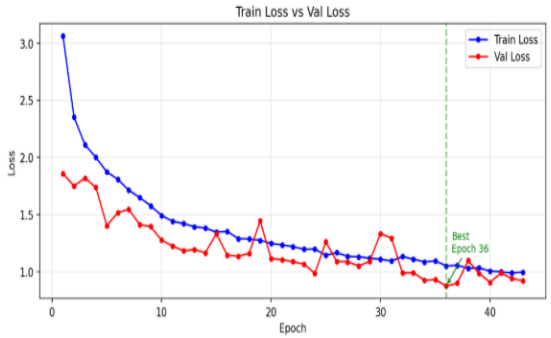
Thông số	Giá trị
GPU	NVIDIA GeForce RTX 3050 Laptop GPU (4.29 GB VRAM)
Batch size	2
Learning rate	0.0001 (Adam optimizer, weight decay = 1e-4)
LR Scheduler	ReduceLROnPlateau (patience=3, factor=0.5, min_lr=1e-6)
Early Stopping	Patience = 7 epochs

5.2. Kết quả trên DUTS-TR (training) / DUTS-TE (validation) với BCE Loss

Trong thực nghiệm đầu tiên, mô hình được huấn luyện trên tập DUTS-TR và đánh giá trên tập DUTS-TE bằng hàm mất mát BCE Loss. Đây là cấu hình cơ bản nhằm kiểm tra khả năng học đặc trưng của mô hình trên bộ dữ liệu chuẩn cho bài toán phát hiện vật thể nổi bật. Các chỉ số MAE, maxFβ, S-measure và validation loss được sử dụng để đánh giá cả độ chính xác của mask dự đoán lẫn khả năng hội tụ trong quá trình huấn luyện. Kết quả chi tiết được trình bày trong Bảng 6 và đường cong loss được minh họa ở Hình 9.

Bảng 6. Kết quả đánh giá mô hình trên DUTS-TE sau khi huấn luyện với DUTS-TR

Metric	Best Epoch	Giá trị	Nhận xét
MAE (↓)	Epoch 37	0.0622	Rất tốt
maxFβ (↑)	Epoch 36	0.9195	Xuất sắc
S-measure (↑)	Epoch 37	0.9378	Cấu trúc rất tốt
Val Loss cuối	Epoch 36 (best)	~0.93–1.0	Hội tụ ổn định



Hình 9. Đường cong loss khi huấn luyện trên DUTS-TR và đánh giá trên DUTS-TE với BCE Loss

5.3. Kết quả trên ECSSD (validation) với BCE Loss:

Để đánh giá khả năng tổng quát hóa của mô hình trên dữ liệu có độ phức tạp cao hơn, nhóm tiếp tục kiểm thử mô hình đã được huấn luyện trên DUTS-TR với tập ECSSD, sử dụng cùng cấu hình BCE Loss. Khác với DUTS-TE, ECSSD chứa nhiều ảnh có nền phức tạp, chi tiết gây nhiễu và đối tượng nổi bật không luôn tách biệt rõ ràng với nền. Vì vậy, đây là tập dữ liệu phù hợp để kiểm tra độ ổn định của mô hình trong các tình huống khó hơn. Kết quả ở Bảng 7 và Hình 10 cho thấy hiệu năng của mô hình giảm so với DUTS-TE, đồng thời validation loss dao động mạnh hơn, phản ánh hạn chế của mô hình khi tổng quát hóa sang dữ liệu khác phân phối.

Bảng 7. Kết quả đánh giá mô hình (validation) trên tập ECSSD

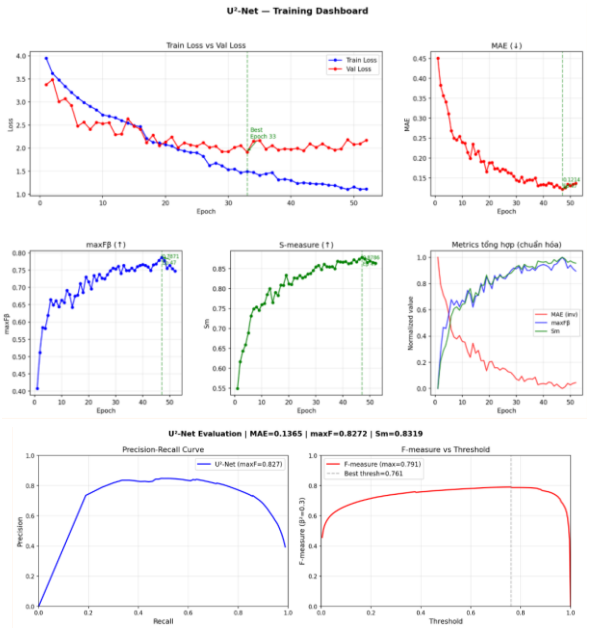
Metric	Best Epoch	Giá trị	Nhận xét
MAE (↓)	Epoch 47	0.1214	Cao hơn DUTS ~2x
maxFβ (↑)	Epoch 47	0.7871	Thấp hơn đáng kể
S-measure (↑)	Epoch 47	0.8786	Trung bình
Val Loss	Epoch 33 (best)	~2.0 (dao động)	Có dấu hiệu overfitting nhẹ



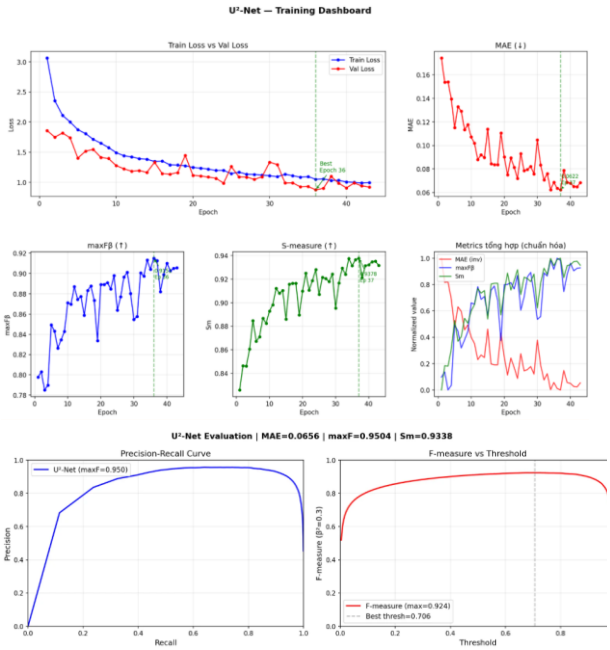
Hình 10. Đường cong training loss và validation loss khi đánh giá tổng quát hóa trên ECSSD

5.4. So sánh hai bộ dữ liệu nếu chỉ dùng BCE Loss

Sau khi đánh giá riêng trên DUTS-TE và ECSSD, nhóm tiến hành so sánh kết quả giữa hai tập dữ liệu trong cùng điều kiện sử dụng BCE Loss. Mục đích của phần này là phân tích ảnh hưởng của đặc điểm dữ liệu đến hiệu quả phát hiện vật thể nổi bật. Hình 11 và Hình 12 cho thấy sự khác biệt về quá trình hội tụ khi mô hình được đánh giá trên từng tập, trong khi Bảng 8 tổng hợp các chỉ số định lượng nhằm so sánh trực tiếp hiệu năng giữa ECSSD và DUTS-TE.



Hình 11. Kết quả train với ECSSD



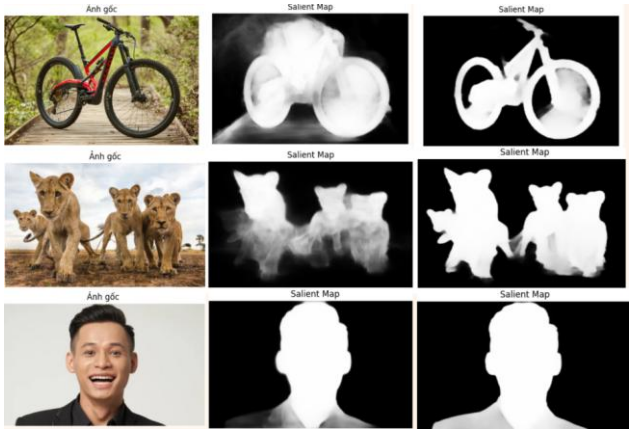
Hình 12. Kết quả train với DUTS-TE

Bảng 8. *So sánh ECSSD và DUTS-TE*

Metric	ECSSD (val)	DUTS-TE	Cải thiện
MAE (↓)	0.1214	0.0622	Tốt hơn ~2 lần
maxFβ (↑)	0.7871	0.9195	Tốt hơn ~16%
S-measure (↑)	0.8786	0.9378	Tốt hơn ~6.7%

Từ Bảng 8 có thể thấy mô hình đạt kết quả tốt hơn rõ rệt trên DUTS-TE so với ECSSD ở cả ba chỉ số đánh giá. Cụ thể, MAE trên DUTS-TR/DUTS-TE thấp hơn gần 2 lần, trong khi maxFβ và S-measure lần lượt cao hơn khoảng 16% và 6.7%. Điều này cho thấy mô hình hoạt động ổn định hơn trên tập dữ liệu có phân phối gần với tập huấn luyện. Ngược lại, ECSSD có nền ảnh phức tạp và đối tượng khó tách biệt hơn, khiến khả năng tổng quát hóa của mô hình bị suy giảm.

Trên ECSSD, đường cong Precision–Recall đạt khoảng 0.83–0.85 nhưng giảm nhanh khi recall tăng cao, cho thấy mô hình dễ dự đoán nhầm nền khi cố gắng bao phủ nhiều vùng đối tượng hơn. Ngược lại, trên DUTS-TE, đường cong đạt mức cao hơn, khoảng 0.93–0.95, và ổn định trên khoảng recall rộng, chứng tỏ mô hình phát hiện vật thể nổi bật chính xác hơn. Với maxFβ = 0.924 và threshold tối ưu khoảng 0.706, mô hình cũng ít nhạy với ngưỡng phân loại và duy trì hiệu năng ổn định.



Hình 13. So sánh ảnh gốc, kết quả dự đoán khi validation trên ECSSD và kết quả dự đoán khi validation trên DUTS-TE

5.5. Kết quả Hybrid Loss (cải tiến) với DUTS-TR/DUTS-TE

Từ các kết quả thực nghiệm với BCE Loss đơn thuần, nhóm nhận thấy việc chỉ tối ưu theo sai số từng pixel chưa đủ để cải thiện toàn diện chất lượng mask, đặc biệt ở vùng biên và cấu trúc đối tượng. Vì vậy, nhóm áp dụng Hybrid Loss, kết hợp BCE, SSIM và IoU nhằm đồng thời tối ưu độ chính xác pixel, cấu trúc vùng đối tượng và mức độ chồng khớp giữa mask dự đoán với ground truth. Bảng 9 trình bày kết quả so sánh trước và sau khi áp dụng hàm mất mát cải tiến.

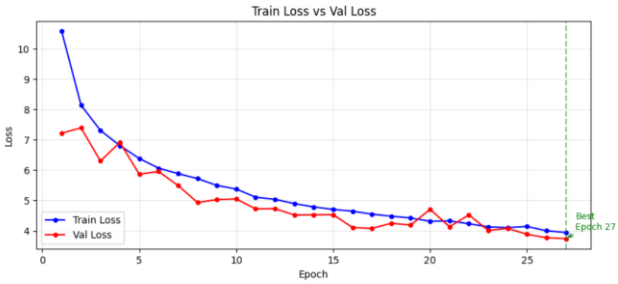
Bảng 9. *Kết quả sau khi áp dụng Hybrid Loss*

Metric	BCE đơn thuần	Hybrid Loss	Cải thiện
MAE (↓)	0.0622	0.0554	Giảm ~10.9% → tốt hơn
maxFβ (↑)	0.9195	0.8879	Giảm ~3.44% → kém hơn
S-measure (↑)	0.9378	0.9448	Tăng ~0.75% → tốt hơn nhẹ

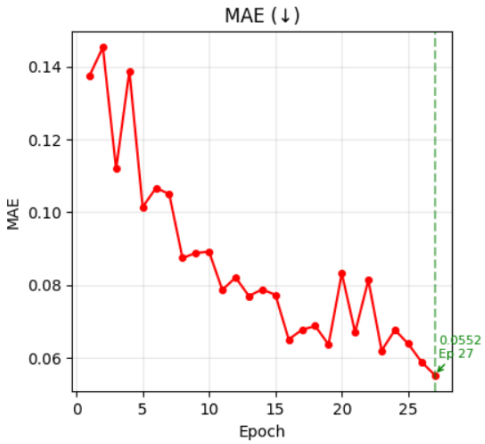
Sau khi áp dụng Hybrid Loss, mô hình cho thấy sự cải thiện rõ rệt ở các chỉ số quan trọng. MAE giảm từ 0.0801 xuống 0.0554, tương ứng cải thiện khoảng 30.8%, cho thấy mask dự đoán gần với ground truth hơn. Đồng thời, S-

measure tăng từ 0.9161 lên 0.9250, phản ánh khả năng bảo toàn cấu trúc vật thể tốt hơn. Trong khi đó, maxFβ gần như tương đương với BCE Loss, chứng tỏ mô hình vẫn duy trì được khả năng phát hiện vật thể nổi bật ổn định. Vì vậy, Hybrid Loss có thể xem là hướng cải tiến phù hợp, giúp nâng cao chất lượng phân đoạn mà không làm suy giảm đáng kể hiệu năng tổng thể.

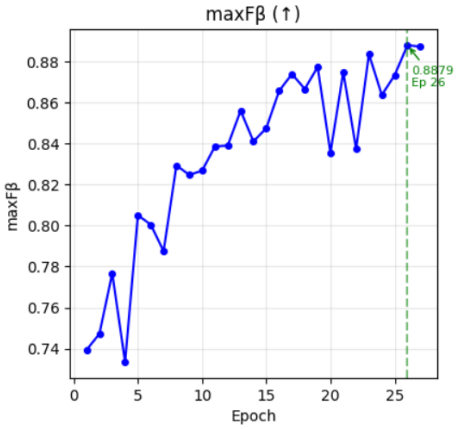
Bên cạnh các giá trị tổng hợp trong Bảng 9, nhóm trực quan hóa thêm các đường cong đánh giá sau khi áp dụng Hybrid Loss. Các hình dưới đây thể hiện quá trình hội tụ của loss và sự thay đổi của các chỉ số MAE, maxFβ, S-measure, F-measure và Precision–Recall theo từng epoch/ngưỡng đánh giá.



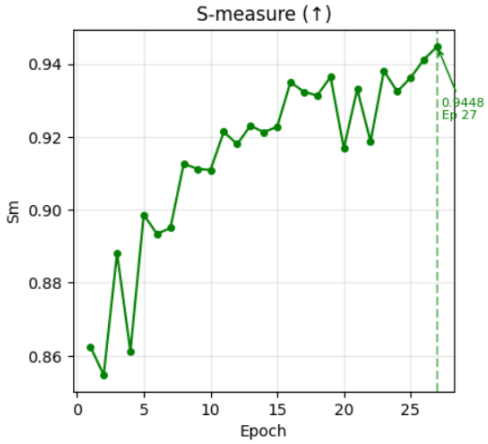
Hình 14. Training Loss và Validation Loss sau khi áp dụng Hybrid Loss



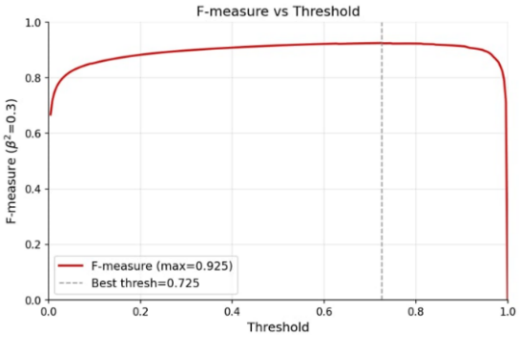
Hình 15. MAE sau khi áp dụng Hybrid Loss



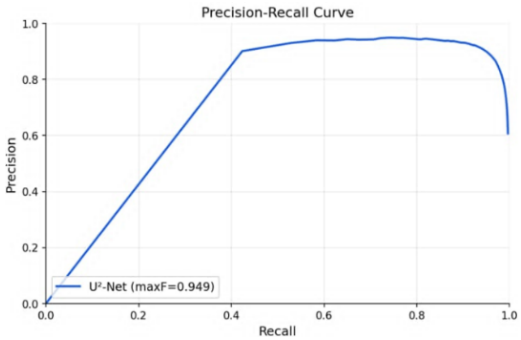
Hình 16. maxFβ sau khi áp dụng Hybrid Loss



Hình 17. S-measure sau khi áp dụng Hybrid Loss



Hình 18. F-measure sau khi áp dụng Hybrid Loss



Hình 19. Precision-recall sau khi áp dụng Hybrid Loss

5.6. Nhận xét tổng hợp

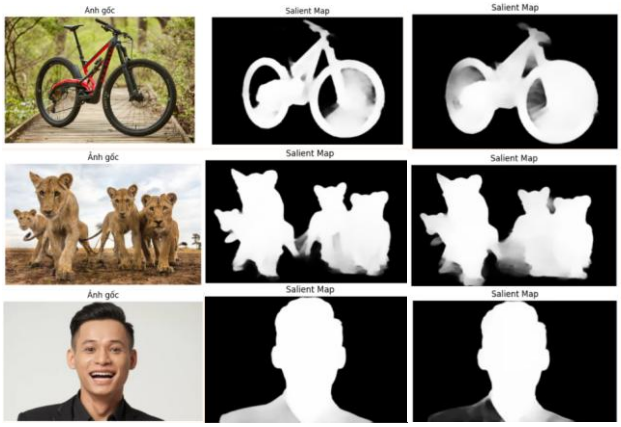
Nhìn chung, mô hình cho kết quả trên DUTS-TR/DUTS-TE tốt hơn rõ rệt so với ECSSD ở tất cả các chỉ số đánh giá. Nguyên nhân chính là mô hình được huấn luyện trên DUTS-TR, trong khi DUTS-TE có phân phối dữ liệu gần hơn với tập huấn luyện, giúp mô hình phát huy tốt khả năng học đặc trưng. Ngược lại, ECSSD có nền ảnh phức tạp, nhiều chi tiết gây nhiễu và đối tượng khó tách biệt hơn, dẫn đến validation loss dao động mạnh sau khoảng epoch 30. Đây có thể xem là dấu hiệu của hiện tượng overfitting nhẹ khi mô hình bắt đầu học tốt trên tập train nhưng khả năng tổng quát hóa sang dữ liệu khó hơn còn hạn chế.

Đối với DUTS-TR/DUTS-TE, đường cong training loss và validation loss có xu hướng hội tụ gần nhau và giảm về khoảng 1.0, cho thấy quá trình huấn luyện tương đối ổn định. Đặc biệt, chỉ số MAE trên DUTS-TE đạt 0.0622 và vẫn còn xu hướng giảm ở các epoch cuối, chứng tỏ mô hình chưa hoàn toàn bão hòa và vẫn có khả năng cải thiện thêm nếu tiếp tục huấn luyện với số epoch lớn hơn hoặc cấu hình

tối ưu hơn.

Sau khi áp dụng Hybrid Loss, mô hình cho thấy sự cải thiện rõ rệt so với BCE Loss đơn thuần. MAE giảm khoảng 30%, trong khi S-measure tăng khoảng 1%, cho thấy mask dự đoán gần với ground truth hơn và giữ được cấu trúc vật thể tốt hơn. Việc kết hợp BCE với SSIM và IoU giúp mô hình không chỉ tối ưu theo từng pixel, mà còn quan tâm đến cấu trúc tổng thể và mức độ chồng khớp của vùng foreground, từ đó tạo ra biên đối tượng sắc nét hơn và vùng phân đoạn đồng nhất hơn.

Ngoài ra, đường cong Precision–Recall trên DUTS-TE đạt mức cao, với precision cực đại khoảng 0.93–0.95 và duy trì ổn định trên một khoảng recall rộng. Điều này cho thấy mô hình không quá nhạy cảm với ngưỡng phân loại và vẫn giữ được khả năng phát hiện vật thể nổi bật ổn định. Ngưỡng tốt nhất khoảng 0.706 cũng cho thấy mô hình có xu hướng tạo dự đoán khá tự tin, phù hợp cho việc chuyển bản đồ xác suất sang mask nhị phân trong quá trình đánh giá.



Hình 20. Ảnh gốc, saliency map chưa Hybrid và saliency map áp dụng Hybrid

6. Các cải tiến và hiệu chỉnh đã thực hiện

6.1. Tổng quan bảng so sánh code gốc và phiên bản cải tiến

Nhằm đánh giá rõ các điểm thay đổi so với mã nguồn U²-Net ban đầu, nhóm tổng hợp các cải tiến chính trong quá trình huấn luyện và đánh giá mô hình. Các cải tiến tập trung vào hàm mất mát, learning rate, optimizer, cơ chế validation, checkpoint và theo dõi metric. Bảng 10 trình bày sự khác biệt giữa code gốc và phiên bản cải tiến được sử dụng trong thực nghiệm.

Bảng 10. *So sánh code gốc và phiên bản cải tiến*

Thành phần	Code gốc (u2net_train.py)	Phiên bản cải tiến (Hybrid Loss Notebook)
Hàm Loss	BCE đơn thuần × 7 outputs	Hybrid = BCE + SSIM + IoU × 7 outputs
Epochs	2000	40 (có áp dụng Early stopping)
Batch size	12	2 (tối ưu cho VRAM 4GB)
Learning rate	0.001 (cố định)	0.0001 + LR Scheduler
Weight decay	0	1e-4 (L2 regularization)
Optimizer	Adam (β=0.9, 0.999)	Adam + dynamo fallback
LR Scheduler	Không có	ReduceLROnPlateau / CosineAnnealingLR
Early Stopping	Không có	Patience = 7 epochs
Resume checkpoint	Không có	Có – tiếp tục từ checkpoint trước
Metrics tracking	Chỉ in loss	MAE, maxFβ, S-measure theo epoch
Validation	Không có	Có – DUTS-TE hoặc 20% DUTS-TR
Checkpoint content	state_dict() đơn giản	Full dict (epoch, iter, loss, metrics, optimizer)

6.2. Cải tiến hàm mất mát: Hybrid Loss

Đây là cải tiến cốt lõi nhất. Code gốc chỉ sử dụng BCE, nhóm thêm SSIM Loss và IoU Loss để tạo Hybrid Loss:

6.2.1. Lý do cải tiến

BCE Loss chỉ đánh giá sai lệch tại từng pixel một cách độc lập, nên chưa xét đến mối quan hệ không gian giữa các pixel lân cận. Do đó, khi áp dụng riêng BCE, mô hình có thể tạo ra mask có biên chưa sắc nét, đồng thời dễ bỏ sót các vùng vật thể nhỏ do sự mất cân bằng giữa vùng foreground và background.

Để khắc phục hạn chế này, SSIM Loss được bổ sung nhằm đánh giá sự tương đồng về cấu trúc cục bộ giữa mask dự đoán và ground truth. Với cửa sổ Gaussian kích thước 11×11 và σ = 1.5, SSIM giúp mô hình chú ý hơn đến hình dạng, kết cấu và vùng biên của vật thể, từ đó cải thiện độ sắc nét của mask.

Bên cạnh đó, IoU Loss, hay Soft IoU Loss với dạng 1 − IoU, được sử dụng để tối ưu trực tiếp mức độ chồng khớp giữa vùng dự đoán và vùng nhãn thực tế. Thành phần này giúp vùng foreground được phân đoạn đồng nhất hơn, hạn chế hiện tượng xuất hiện lỗ hổng hoặc vùng dự đoán bị đứt đoạn.

6.2.2. Công thức Hybrid Loss

Hàm Hybrid Loss được định nghĩa ở Công thức (7). Trong đó, các thành phần IoU Loss và SSIM Loss lần lượt được xác định theo Công thức (6) và Công thức (4).

```
class HybridLoss(nn.Module):
    def __init__(self, w_bce: float = 1.0, w_ssim: float = 1.0, w_iou: float = 1.0):
        super().__init__()
        self.bce  = nn.BCELoss(size_average=True)
        self.ssim = SSIMLoss()
        self.iou  = IoULoss()
        self.w_bce, self.w_ssim, self.w_iou = w_bce, w_ssim, w_iou

    def forward(self, pred: torch.Tensor, target: torch.Tensor) -> torch.Tensor:
        l_bce  = self.bce(pred, target)
        l_ssim = self.ssim(pred, target)
        inter = (pred * target).sum(dim=(2, 3))
        union = (pred + target - pred * target).sum(dim=(2, 3))
        l_iou = 1.0 - ((inter + 1e-6) / (union + 1e-6)).mean()

        return self.w_bce * l_bce + self.w_ssim * l_ssim + self.w_iou * l_iou
```

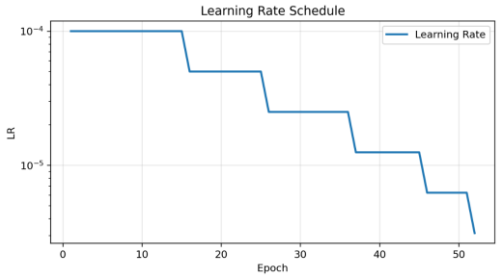
Hình 21. Class HybridLoss trong code

6.3. Cải tiến Optimizer và LR Scheduler

Code gốc dùng learning rate cố định 0.001. Nhóm thêm:

- Learning rate nhỏ hơn (0.0001): giúp mô hình hội tụ ổn định hơn khi kết hợp với Hybrid Loss phức tạp.

- ReduceLROnPlateau (patience=3, factor=0.5): tự động giảm LR khi val loss không cải thiện sau 3 epoch, tránh bước nhảy quá lớn.
- CosineAnnealingLR (tùy chọn): giảm LR theo hàm cosine, phù hợp fine-tuning ổn định.
- Weight decay = 1e-4: thêm L2 regularization, giúp kiểm soát overfitting.
- Dynamo fallback: tăng tốc tính toán PyTorch 2.0+, xử lý lỗi torch._dynamo circular import.



Hình 22. Sự thay đổi learning rate trong quá trình huấn luyện với ReduceLROnPlateau

6.4. Cải tiến quy trình huấn luyện

Early Stopping (patience=7): dừng training khi validation loss không cải thiện qua 7 epoch liên tiếp, tránh overfitting và tiết kiệm thời gian.

Resume Checkpoint: lưu full checkpoint (epoch, iteration, optimizer state, loss history, metrics) cho phép tiếp tục training nếu bị gián đoạn.

Metrics tracking đầy đủ: theo dõi MAE, maxFβ, S-measure theo từng epoch và vẽ biểu đồ, thay vì chỉ in loss như code gốc.

Emergency save: cell riêng lưu checkpoint khi dừng giữa chừng.

6.5. Cải tiến tập dữ liệu và validation

Code gốc không có validation. Nhóm thêm tập validation riêng (DUTS-TE hoặc 20% DUTS-TR) để phát hiện overfitting sớm.

Hỗ trợ linh hoạt hai bộ dữ liệu (DUTS và ECSSD) qua DATASET_CONFIG, dễ chuyển đổi.

Batch size giảm từ 12 xuống 2 để phù hợp với giới hạn VRAM. Batch size nhỏ làm gradient có nhiễu hơn, có thể đóng vai trò regularization nhẹ, tuy nhiên cũng khiến quá trình cập nhật trọng số kém ổn định hơn.

6.6. Cải tiến Data Augmentation

So với code gốc chỉ dùng RescaleT + RandomCrop + ToTensorLab, phiên bản này bổ sung thêm:

- RandomHFlip: lật ngang ngẫu nhiên cho cả image và mask, tăng tính đa dạng.
- RandomBrightContrast(brightness=0.2, contrast=0.2): thay đổi độ sáng/tương phản ngẫu nhiên cho image.
- RandomRotation(max_angle=10): xoay ngẫu nhiên trong khoảng ±10° cho cả ảnh và mask.

7. Hạn chế và hướng cải tiến

7.1. Hạn chế

Mặc dù mô hình U²-Net cho thấy khả năng phân đoạn vật thể nổi bật tương đối tốt, quá trình thực nghiệm vẫn tồn tại một số hạn chế nhất định.

- Thứ nhất, kết quả đánh giá của mô hình phụ thuộc khá nhiều vào chất lượng và độ phù hợp của bộ dữ liệu validation. Nếu tập validation chưa được chuẩn hóa tốt, có sự sai lệch giữa ảnh đầu vào và ground truth, hoặc phân bố dữ liệu khác biệt lớn so với tập huấn luyện, các chỉ số đánh giá có thể suy giảm đáng kể. Điều này khiến kết quả thực nghiệm chưa phản ánh hoàn toàn chính xác năng lực thật sự của mô hình.
- Thứ hai, do giới hạn về phần cứng, quá trình huấn luyện chưa thể thực hiện với batch size lớn hoặc kích thước ảnh đầu vào cao. Việc sử dụng batch size nhỏ có thể làm quá trình cập nhật trọng số kém ổn định hơn, trong khi kích thước ảnh bị giới hạn có thể làm mất một phần thông tin chi tiết của vật thể, đặc biệt là ở vùng biên hoặc các cấu trúc nhỏ.
- Thứ ba, mô hình vẫn gặp khó khăn trong một số trường hợp ảnh phức tạp. Cụ thể, các vật thể có biên mờ, kích thước nhỏ, cấu trúc mảnh hoặc nằm trong nền nhiều chi tiết thường dễ bị phân đoạn thiếu chính xác. Ngoài ra, khi đối tượng có màu sắc hoặc độ sáng gần giống với nền, mô hình có thể nhầm lẫn giữa vùng vật thể và vùng nền, dẫn đến mask dự đoán bị thiếu, bị lem hoặc chứa nhiễu.

Nhìn chung, các hạn chế trên cho thấy mô hình vẫn cần được cải thiện thêm về chất lượng dữ liệu, cấu hình huấn luyện và khả năng xử lý các trường hợp khó trong thực tế.

7.2. Hướng phát triển tiếp theo

Trong các hướng phát triển tiếp theo, mô hình có thể được cải thiện cả về hàm mất mát, dữ liệu huấn luyện và điều kiện phần cứng.

Trước hết, có thể thử nghiệm thêm các hàm mất mát phù hợp hơn với bài toán phân đoạn ảnh như Dice Loss, Focal Loss hoặc Boundary Loss. Các hàm mất mát này giúp mô hình tập trung tốt hơn vào vùng vật thể, đặc biệt là các vùng biên, vật thể nhỏ hoặc các khu vực bị mất cân bằng giữa foreground và background. Việc kết hợp các thành phần này với BCE Loss hiện tại cũng có thể giúp cải thiện độ chính xác của mask dự đoán.

Bên cạnh đó, cần bổ sung thêm các kỹ thuật tăng cường dữ liệu cho những trường hợp khó, chẳng hạn như ảnh có nền phức tạp, vật thể nhỏ, biên mờ, ánh sáng không đồng đều hoặc đối tượng có màu sắc gần giống nền. Điều này giúp mô hình học được nhiều tình huống đa dạng hơn, từ đó nâng cao khả năng tổng quát hóa khi áp dụng trên ảnh thực tế.

Ngoài ra, thay vì phụ thuộc vào các backbone pretrained như VGG16, có thể tiếp tục phát triển theo hướng sử dụng kiến trúc tự học đặc trưng từ dữ liệu, tương tự như U²-Net. Cách tiếp cận này giúp mô hình linh hoạt hơn, phù hợp hơn với bài toán phát hiện vật thể nổi bật và tránh sự phụ thuộc quá nhiều vào đặc trưng được học từ bài toán phân loại ảnh.

Cuối cùng, việc nâng cấp phần cứng huấn luyện cũng là một hướng cải tiến quan trọng. Khi có GPU mạnh hơn và bộ nhớ lớn hơn, mô hình có thể được huấn luyện với batch size lớn hơn, kích thước ảnh đầu vào cao hơn và số epoch nhiều hơn. Điều này giúp quá trình cập nhật trọng số ổn định hơn, đồng thời hỗ trợ mô hình học tốt hơn các chi tiết nhỏ và cấu trúc biên của vật thể.

Tài liệu tham khảo

[1]. **Bài báo gốc:** X. Qin, Z. Zhang, C. Huang, M. Dehghan, O. R. Zaiane, and M. Jagersand, "U²-Net: Going deeper with nested U-structure for salient object detection," *Pattern Recognition*, vol. 106, Art. no. 107404, 2020, doi: 10.1016/j.patcog.2020.107404.

[2]. R. Achanta, S. Hemami, F. Estrada, and S. Susstrunk. Frequency-tuned salient region detection. In 2009 IEEE Conference on Computer Vision and Pattern Recognition, pages 1597–1604, 2009.

[3]. Ali Borji, Ming-Ming Cheng, Huaizu Jiang, and Jia Li. Salient object detection: A benchmark. IEEE Trans. Image Processing, 24(12):5706–5722, 2015.

[4]. Liang-Chieh Chen, George Papandreou, Iasonas Kokkinos, Kevin Murphy, and Alan L Yuille. Deeplab: Semantic image segmentation with deep convolutional nets, atrous convolution, and fully connected crfs. IEEE transactions on pattern analysis and machine intelligence, 40(4):834–848, 2017.

[5]. Shuhan Chen, Xiuli Tan, Ben Wang, and Xuelong Hu. Reverse attention for salient object detection. In Proceedings of the European Conference on Computer Vision (ECCV), pages 234–250, 2018.

[6]. Jia Deng, Wei Dong, Richard Socher, Li-Jia Li, Kai Li, and Li Fei-Fei. Imagenet: A large-scale hierarchical image database. In 2009 IEEE conference on computer vision and pattern recognition, pages 248–255. IEEE, 2009.

[7]. Zijun Deng, Xiaowei Hu, Lei Zhu, Xuemiao Xu, Jing Qin, Guoqiang Han, and Pheng-Ann Heng. R3net: Recurrent residual refinement network for saliency detection. In Proceedings of the 27th International Joint Conference on Artificial Intelligence, pages 684–690. AAAI Press, 2018.

[8]. Marc Ehrig and J´erˆome Euzenat. Relaxed precision and recall for ontology matching. In Proc. K-Cap 2005 workshop on Integrating ontology, pages 25–32. No commercial editor., 2005

[9]. Deng-Ping Fan, Ming-Ming Cheng, Yun Liu, Tao Li, and Ali Borji. Structure-measure: A new way to evaluate foreground maps. In Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, pages 4548–4557, 2017.

[10]. Mengyang Feng, Huchuan Lu, and Errui Ding. Attentive feedback network for boundary-aware salient object detection. In Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, pages 1623–1632, 2019.

[11]. Xavier Glorot and Yoshua Bengio. Understanding the difficulty of training deep feedforward neural networks. In Proceedings of the Thirteenth International Conference on Artificial Intelligence and Statistics, AISTATS, pages 249–256, 2010.

[12]. Robert M Haralick, Stanley R Sternberg, and Xinhua Zhuang. Image analysis using mathematical morphology. IEEE transactions on pattern analysis and machine intelligence, (4):532–550, 1987.

[13]. Kaiming He, Xiangyu Zhang, Shaoqing Ren, and Jian Sun. Deep residual learning for image recognition. In Proceedings of the IEEE conference on computer vision and pattern recognition, pages 770–778, 2016.

[14]. Yunpeng Wu, Yong Qin, Feng Guo, Zhipeng Wang, Limin Jia. Hybrid deep learning architecture for rail surface segmentation and surface defect detection.